

Ćwiczenie 1

Potęga danych: Przypadek Airbnb

- **Termin oddania:** 25 października 2026 r. do godziny 23:55.
- **Rozmowa oceniająca (wywiad):** odbędzie się podczas sesji laboratoryjnej 29 października 2026 r.
- **Organizacja:** Ćwiczenie realizowane jest w grupach dwu- lub trzyosobowych.
- **Sposób oddania:** Na platformie Wirtualny Kampus należy przesłać raport w formacie PDF opisujący sposób rozwiązywania zadania oraz wszystkie użyte kody/skrypty (wymagane jest tylko jedno zgłoszenie na grupę).
- **Waga oceny:** Ocena z tego ćwiczenia stanowi 20% oceny końcowej z przedmiotu (wymagana ocena minimalna to 3.0).

Motywacja i cele

W epoce cyfrowej, w której obecnie żyjemy, dane stanowią fundamentalny zasób dla organizacji w osiąganiu ich celów i budowaniu przewagi konkurencyjnej. Jednakże samo posiadanie danych nie wystarczy; konieczne jest ich odpowiednie przeanalizowanie i zinterpretowanie, aby odkryć trendy lub wzorce, przewidywać zachowania, wyprzedzać wydarzenia, wcześniej wykrywać problemy i podejmować świadome decyzje strategiczne.

Zatem organizacje, które potrafią właściwie wykorzystać dane, znajdują się w uprzywilejowanej pozycji, pozwalającej na adaptację do zmian, innowacje i utrzymanie konkurencyjności w coraz bardziej złożonym i dynamicznym środowisku biznesowym. Z tego powodu ukuto powiedzenie "informacja to potęga". Wszystkie te zasoby są dziś wykorzystywane w dziedzinie *Data Science*, która staje się coraz ważniejsza w strukturach organizacji.¹

W tym ćwiczeniu będziemy doskonalić praktyczne umiejętności w zakresie eksploracyjnej analizy danych z wykorzystaniem zbiorów danych udostępnionych przez Airbnb. W szczególności oczekuje się, że studenci będą potrafili:

- Zrozumieć strukturę i zawartość danych z platformy Airbnb.
- Zastosować techniki czyszczenia danych, aby rozwiązać powszechne problemy, takie jak brakujące wartości i wartości odstające (*outliers*).
- Przeprowadzić pełną analizę opisową, wykorzystując narzędzia statystyczne i wizualizacyjne do zbadania podstawowych cech danych.
- Zidentyfikować wzorce, trendy i istotne korelacje w danych Airbnb.
- Skutecznie zinterpretować i zkomunikować wyniki analizy eksploracyjnej

Zbiory danych

Kierując się filozofią otwartych danych (*Open Data*), firma Airbnb dołączyła do tej inicjatywy poprzez projekt **Inside Airbnb**, w ramach którego udostępnia dane o ofertach noclegowych z ponad stu miast na całym świecie. Dane te są dostępne pod następującym linkiem: <https://insideairbnb.com/get-the-data>.

Wymóg: W ramach tego ćwiczenia musicie przeanalizować dane z co najmniej **dwóch miast**. Wybór tych miast należy do decyzji każdej z grup.

Dla każdego miasta znajdziecie szereg plików. W celu realizacji tego ćwiczenia zalecamy skupienie się na następujących:

- **Plik `listings.csv.gz`:** Plik CSV zawierający szczegóły ofert w danym mieście. Każda oferta (zakwaterowanie) ma około 70 wymiarów/zmiennych określających jej cechy (wymiały `name`, `description`, `property_type`, `room_type`, `bedrooms`, `bathrooms`, `amenities` ...), lokalizację (wymiały `latitude`, `longitude`, `neighbourhood` ...), gospodarza (wymiały `host_*`), dostępność (wymiały `price`², `minimum_nights`, `maximum_nights`, `availability_*` ...) oraz wskaźniki recenzji i ocen (wymiały `number_of_reviews`, `review_scores_*` ...).
- **Plik `neighbourhoods.geojson`:** Plik GeoJSON³ zawierający informacje geograficzne o dzielnicach danego miasta.

Jeśli macie jakiegokolwiek wątpliwości co do znaczenia danego pliku lub wymiaru, możecie skonsultować się ze słownikiem danych (*Data Dictionary*) dostępnym na podanej wyżej stronie.

Część 1: Eksploracyjna analiza danych

Analiza eksploracyjna (ang. *Exploratory Data Analysis - EDA*) to statystyczne podejście używane do eksploracji, opisu, podsumowania i zrozumienia badanych danych. Tego typu analizy są niezwykle użyteczne przed przystąpieniem do bardziej zaawansowanych technik, takich jak eksploracja danych (*Data Mining*) czy filtrowanie kolaboratywne.

Na początek będziecie musieli zbadać poszczególne zmienne w celu poznania podstawowych cech danych. W zależności od tego, czy zmienne są jakościowe czy ilościowe, będziecie musieli zastosować odpowiednie techniki, aby zinterpretować te dane. Obejmuje to obliczanie tabel częstości oraz statystyk opisowych, takich jak mediany, średnie, kwartyle, odchylenie standardowe oraz inne omówione na zajęciach. Należy również wygenerować odpowiednie wizualizacje za pomocą wykresów słupkowych, kołowych, histogramów i wykresów pudełkowych (*boxplots*).

² Chociaż w plikach zawsze pojawia się symbol '\$', wartość liczbową zależy od waluty danego kraju. Na przykład w miastach UE i Wielkiej Brytanii oznacza to odpowiednio euro i funty szterlingi.

³ Zawartość tego typu plików można wizualizować za pomocą narzędzia online: <https://geojson.io>

Następnie będziecie musieli zagłębić się w badanie korelacji między wieloma zmiennymi za pomocą modeli regresji (liniowej lub nieliniowej), obliczania współczynników korelacji, testów statystycznych i wykresów punktowych (rozrzutu). Zbadanie tych zmiennych i korelacji pozwoli wam na dokonywanie porównań między ofertami z różnych miast i ustalenie stopnia ich podobieństwa.

Możecie na przykład zbadać, czy cechy lub dostępność ofert są podobne w różnych miastach, czy rozkład cen różni się między miastami (lub czy zależy to od jakiejś innej zmiennej), czy istnieją gospodarze, którzy dominują na rynku, lub co sprawia, że oferty mają wyższe oceny. Tego typu badania są oczekiwane w eksploracyjnej analizie danych. Macie pełną swobodę w stawianiu hipotez i badaniach, które uznacie za interesujące.

Oczekiwany rezultat (Część 1): W raporcie musicie jasno wskazać, jakie badania przeprowadziliście. Dla każdego z nich należy wyjaśnić procedurę zastosowaną do jego rozwiązania: od użytych zmiennych, technik i statystyk, po prezentację wyników za pomocą wykresów oraz wyciągnięte wnioski. Oznacza to, że nie należy poprzestawać tylko na samej odpowiedzi czy wizualizacji — należy uzasadnić, jak sformułowano i rozwiązano każdy problem.

Część 2: Wizualizacje geograficzne

Analiza danych w aspekcie geograficznym jest kluczowa w systemach takich jak Airbnb, gdzie lokalizacja odgrywa decydującą rolę. Poprzez analizę przestrzenną można lepiej zrozumieć dystrybucję zakwaterowań, zidentyfikować specyficzne wzorce regionalne oraz sprawdzić, jak czynniki geograficzne wpływają na ceny i popyt.

Wykorzystując wiedzę zdobytą w pierwszej części ćwiczenia, musicie stworzyć wizualizacje geograficzne, aby przedstawić zmienne, które uznacie za najbardziej interesujące z perspektywy przestrzennej. W tym celu należy stworzyć mapy kartogramowe (tzw. *choropleth maps*, z pomocą plików GeoJSON), mapy kategoryjne, bąbelkowe i/lub mapy ciepła (korzystając z szerokości i długości geograficznej ofert).

Zamiast tworzyć wyłącznie statyczne mapy, powinniście dodać funkcjonalności tworzące interaktywne wizualizacje. Można na przykład dodać selektory warstw (*layer controls*), korzystać z różnych warstw bazowych poprzez dostawców TMS (*Tile Map Service*), dostosowywać skale kolorów oraz zaimplementować interakcje użytkownika (np. wyświetlanie dodatkowych informacji po kliknięciu na element mapy).

Oczekiwany rezultat (Część 2): Podobnie jak w części 1, należy szczegółowo udokumentować procedurę dla każdego badania przestrzennego, od wykorzystanych struktur danych po ostateczne wnioski i interpretację map.

Implementacja

Możecie wykorzystać dowolne języki programowania (Python, R, Java, Javascript...) oraz preferowane przez was biblioteki (pandas, NumPy, Matplotlib, ggplot2, Leaflet, Folium, Plotly...). **Uwaga:** Zabrania się korzystania z gotowych klientów i programów GIS, takich jak Google Earth lub QGIS, do tworzenia wymaganych wizualizacji geograficznych (całość musi być wygenerowana z poziomu kodu/skryptu).

Ocena (Avaluació)

Ocena będzie premiować przede wszystkim ilość, jakość, stopień trudności i oryginalność przeprowadzonych badań, a także poprawność techniczną i formalną raportu.

- Zarówno analiza eksploracyjna, jak i wizualizacje geograficzne są **obowiązkowe**. Niewykonanie którejkolwiek z części skutkuje oceną 0.
- Wykrycie plagiatu lub nieuprawnionego kopiowania skutkuje automatyczną oceną 0.

Podział punktacji:

- Zakres zastosowanego rozwiązania: **20%**
- Jakość techniczna eksploracyjnej analizy danych: **40%**
- Jakość techniczna wizualizacji geograficznych: **30%**
- Poprawność formalna i jakość dokumentacji: **10%**

Dostarczenie rozwiązania (Lliurament)

Oddanie zadania nastąpi za pośrednictwem dedykowanego zadania na Wirtualnym Kampusie (Campus Virtual) **do 25 października 2026 roku do godziny 23:55**. Należy przesłać plik archiwum ZIP zawierający:

1. Raport w formacie PDF (zaleca się użycie systemu LaTeX, np. za pomocą platformy Overleaf) szczegółowo wyjaśniający rozwiązanie ćwiczenia.
2. Wszystkie użyte kody i skrypty.

Rozmowa oceniająca (Entrevista)

Rozmowa na temat ćwiczenia odbędzie się podczas sesji laboratoryjnej w dniu **29 października 2026 r.** W trakcie tego wywiadu prowadzący zada członkom grupy pytania mające na celu potwierdzenie autorstwa pracy oraz ocenę poziomu wiedzy zdobytej przez studentów. Odbycie rozmowy jest obowiązkowe; w przeciwnym razie ćwiczenie nie zostanie ocenione.